



- 본 과제는 학회 정규 세션 「Linear Algebra」, 「Basic Statistics」 및 「Math for ML」 일부 내용을 다루며, 개념의 이해와 실제 활용 사례에 대한 이해를 돕기 위해 기획되었습니다. 평가를 위한 것이 아니므로, 주어진 힌트를 적극 활용하시고 학회원 간 토론, Slack의 질의응답을 활용하여 해결해주시요. 단, 답안 표절은 금지합니다.
- 2/11 (수) 23시 59분까지 Github 에 PDF 파일 하나로 제출해주시요. Github에 제출하는 방법을 모른다면 학술부장 혹은 과제 질의응답을 위한 오픈채팅방을 활용해주시요.

문제 1 선형대수 기초 (Linear Algebra Basic)

1. $Ax = b$ 의 동치 조건

$n \times n$ 정사각행렬 A 에 대하여 다음 조건들은 동치(equivalent)입니다.

- 행렬 A 는 가역적(invertible)이다.
- 임의의 $n \times 1$ 벡터 b 에 대하여 방정식 $Ax = b$ 는 유일한 해를 갖는다.
- 동차 방정식(Homogeneous equation) $Ax = 0$ 은 오직 자명한 해(trivial solution, $x = 0$)만을 갖는다.

1-1. 다음과 같은 삼변수 함수 $f(x, y, z)$ 가 주어져 있습니다.

$$f(x, y, z) = x^2 + y^2 + 1.5z^2 + xy + yz + zx$$

Handwritten notes: $\frac{\partial^2 f}{\partial x^2} = 2, \frac{\partial^2 f}{\partial y^2} = 2, \frac{\partial^2 f}{\partial z^2} = 3$
 $\frac{\partial^2 f}{\partial x \partial y} = 1, \frac{\partial^2 f}{\partial y \partial z} = 1, \frac{\partial^2 f}{\partial z \partial x} = 1$

- (1) 이 함수의 헤시안 행렬(Hessian Matrix) A 를 구하고 PD(Positive Definite), PSD, ND, NSD 중 무엇인지 판별하시요.

$$A = \begin{pmatrix} 2 & 1 & 1 \\ 1 & 2 & 1 \\ 1 & 1 & 3 \end{pmatrix} \quad \text{PD}$$

- (2) 위에서 구한 행렬 A 의 역행렬 A^{-1} 을 계산하시요.

$$A^{-1} = \frac{1}{\pi} \begin{pmatrix} 5 & -2 & -1 \\ -2 & 5 & -1 \\ -1 & -1 & 3 \end{pmatrix}$$

- (3) 만약 특정 상수 k 에 대해 함수의 항 xy 가 kxy 로 변하여 $\det(A) = 0$ 이 된다면, 조건 (b)는 여전히 성립하는가? 그 이유를 행렬식(determinant)과 관련지어 설명하시요.

$$A(k) = \begin{pmatrix} 2 & k & 1 \\ k & 2 & 1 \\ 1 & 1 & 3 \end{pmatrix}, \quad \det(A(k)) = 0 \text{ 이면 } A(k) \text{는 특이행렬} \rightarrow \text{역행렬} \times$$

1-2. (Optional)

- (1) (a), (b), (c) 세 조건들이 동치임을 증명하시요.

\rightarrow 조건 (b) 성립 X

- (2) 행렬 A 가 가역적이라고 가정할 때, 임의의 b 에 대하여 $Ax = b$ 를 만족하는 해 x 가 항상 존재함을 대수적으로 유도하여 증명하고 해당 증명의 의미를 서술하시요.

문제 2 특이값 분해 (SVD)

특이값 분해(SVD)는 대각화와 달리 모든 크기의 행렬에 대해 적용이 가능하며, 그 계산 과정은 다음과 같습니다.

- 1) 항상 대칭 행렬을 이루는 두 행렬 $B^T B, B B^T$ 를 계산하고, 이들의 고유값을 계산해 특이값 σ 와 고유 벡터를 통해 직교대각화하여 $B^T B = V D V^T, B B^T = U D U^T$ 를 구합니다.
- 2) 0이 아닌 특이값들을 내림차순으로 나열하여 Σ 를 구성하고, 이들을 모두 활용해 $A = U \Sigma V^T$ 를 구합니다.

다음 행렬 B 에 특이값 분해를 적용하였을 때 나오는 행렬 U, Σ, V^T 를 각각 구하시오.

$$B = \begin{bmatrix} 1 & 1 & 0 \\ 0 & 0 & 1 \end{bmatrix}$$

$$1) \quad B B^T = \begin{pmatrix} 1 & 1 & 0 \\ 0 & 0 & 1 \end{pmatrix} \begin{pmatrix} 1 & 0 \\ 1 & 0 \\ 0 & 1 \end{pmatrix} = \begin{pmatrix} 2 & 0 \\ 0 & 1 \end{pmatrix}$$

$$\sigma_1 = \sqrt{2}, \quad \sigma_2 = 1$$

$$U = \begin{pmatrix} 1 & 0 \\ 0 & 1 \end{pmatrix}$$

$$2) \quad B^T B = \begin{pmatrix} 1 & 1 & 0 \\ 1 & 1 & 0 \\ 0 & 0 & 1 \end{pmatrix}$$

$$\therefore V = \begin{pmatrix} \frac{1}{\sqrt{2}} & 0 & -\frac{1}{\sqrt{2}} \\ \frac{1}{\sqrt{2}} & 0 & \frac{1}{\sqrt{2}} \\ 0 & 1 & 0 \end{pmatrix},$$

$$V^T = \begin{pmatrix} \frac{1}{\sqrt{2}} & \frac{1}{\sqrt{2}} & 0 \\ 0 & 0 & 1 \\ -\frac{1}{\sqrt{2}} & \frac{1}{\sqrt{2}} & 0 \end{pmatrix}$$

$$\begin{aligned} \lambda = 2 & ; \quad v_1 = \frac{1}{\sqrt{2}}(1, 1, 0)^T \\ \lambda = 1 & ; \quad v_2 = (0, 0, 1)^T \\ \lambda = 0 & ; \quad v_3 = \frac{1}{\sqrt{2}}(-1, 1, 0)^T \end{aligned}$$

$$\Sigma = \begin{pmatrix} \sqrt{2} & 0 & 0 \\ 0 & 1 & 0 \end{pmatrix}$$

문제 3 Convex Sets & Functions

3-1. Convex Set 집합 C의 임의의 두 점 x_1, x_2 와 $0 \leq \theta \leq 1$ 일 때,
 $\theta x_1 + (1-\theta)x_2 \in C$ 이면 C는 convex set

1. 다음 집합들이 Convex set 인지 증명하시오.

C1)

$$u = (x_1, y_1), v = (x_2, y_2) \in C_1$$

$$x_1 + y_1 \leq 1,$$

$$x_2 + y_2 \leq 1$$

$$\theta(x_1 + y_1) + (1-\theta)(x_2 + y_2) \leq \theta \cdot 1 + (1-\theta) \cdot 1 = 1$$

$$\therefore \theta u + (1-\theta)v \in C_1 \rightarrow \text{convex}$$

$$C_1 = \{(x, y) \in \mathbb{R}^2 : x + y \leq 1\}$$

$$C_2 = \{x \in \mathbb{R}^n : \|x\|_1 \leq 1\}$$

$$C_3 = \{(x, y) \in \mathbb{R}^2 : y \geq e^x\}$$

$$C3) f(x) = e^x$$

$$f'(x) = e^x > 0 \text{ 이므로}$$

증명가능한 것은 convex

C2) $x, y \in C_2$ 가정

$$\|x\|_1 \leq 1, \|y\|_1 \leq 1$$

$$\|\theta x + (1-\theta)y\|_1 \leq \|\theta x\|_1 + \|(1-\theta)y\|_1 = \theta \|x\|_1 + (1-\theta) \|y\|_1 \leq \theta + (1-\theta) = 1$$

2. 함수 $f: \mathbb{R}^n \rightarrow \mathbb{R}$ 가 convex function 일 때, f 의 epigraph인 집합 S 가 convex set임을 보이시오. $\theta(1) + (1-\theta)(1) = 1 \therefore \text{convex}$

$$S = \{(x, t) \in \mathbb{R}^n \times \mathbb{R} : t \geq f(x)\}$$

$$(x_1, t_1), (x_2, t_2) \in S$$

$$t_1 \geq f(x_1), t_2 \geq f(x_2)$$

$$\theta t_1 + (1-\theta)t_2 \geq \theta f(x_1) + (1-\theta)f(x_2) \geq f(\theta x_1 + (1-\theta)x_2)$$

$$(\theta x_1 + (1-\theta)x_2, \theta t_1 + (1-\theta)t_2) \in S$$

$\therefore S$ 는 convex set

3-2. Convex Function

1. Convex 함수의 합성

$f: \mathbb{R}^d \rightarrow \mathbb{R}$ 가 실수 값을 갖는 함수라고 합시다. $\nearrow h(x)$

(a) 함수 $f(x)$ 와 $g(x)$ 가 convex일 때, $f(x) + g(x)$ 또한 convex임을 보이시오.

$$h(\theta x + (1-\theta)y) = f(\theta x + (1-\theta)y) + g(\theta x + (1-\theta)y) \leq [\theta f(x) + (1-\theta)f(y)] + [\theta g(x) + (1-\theta)g(y)]$$

(b) A 와 b 가 호환되는 크기의 행렬과 벡터라고 합시다. $f(x)$ 가 convex라면 $f(Ax + b)$ 또한 convex임을 보이시오.

$$h(x) = f(Ax + b)$$

$$h(\theta x + (1-\theta)y) = f(A(\theta x + (1-\theta)y) + b)$$

2. Convex Optimization

$$f(\theta(Ax + b) + (1-\theta)(Ay + b))$$

또 다른 함수 $f: \mathbb{R}^d \rightarrow \mathbb{R}$ 를 고려해 봅시다. $\leq \theta f(Ax + b) + (1-\theta)f(Ay + b) = \theta h(x) + (1-\theta)h(y)$

$$f(x) = \|Ax - b\|^2.$$

$$\therefore \text{convex}$$

오직 convex 함수의 정의만을 사용하여, $f(x)$ 가 $x \in \mathbb{R}^d$ 에서 convex임을 보이시오.

$$f(\theta x + (1-\theta)y) = \|A(\theta x + (1-\theta)y) - b\|^2$$

$$= \|\theta(Ax - b) + (1-\theta)(Ay - b)\|^2$$

$$u = Ax - b$$

$$v = Ay - b$$

$$\|\theta u + (1-\theta)v\|^2 \leq \theta \|u\|^2 + (1-\theta)\|v\|^2$$

$$= \theta \|Ax - b\|^2 + (1-\theta)\|Ay - b\|^2$$

$$= \theta f(x) + (1-\theta)f(y)$$

$\therefore f$ 는 convex

문제 4 정보이론 (Information Theory)

4-1. Entropy

확률분포 $p(x, y)$ 가 다음과 같이 주어졌다고 합시다.

$X \backslash Y$	0	1
0	$\frac{1}{3}$	$\frac{1}{3}$
1	0	$\frac{1}{3}$

$$\begin{aligned} p(0,0) &= \frac{1}{3} & p(x=0) &= \frac{2}{3} \\ p(0,1) &= \frac{1}{3} & p(x=1) &= \frac{1}{3} \\ p(1,0) &= 0 & p(y=0) &= \frac{1}{3} \\ p(1,1) &= \frac{1}{3} & p(y=1) &= \frac{2}{3} \end{aligned}$$

다음 값들을 구하시오.

- (a) $H(X), H(Y)$. $H(X) = \log_2 3 - \frac{2}{3} = 0.918$
 $H(Y) = \log_2 3 - \frac{2}{3} = 0.918$
- (b) $H(X|Y), H(Y|X)$. $H(X,Y) - H(X) = 1.585 - 0.918 = 0.667$
 $H(X,Y) - H(Y) = 1.585 - 0.918 = 0.667$
- (c) $H(X,Y)$. $= \log_2 3$
- (d) $H(Y) - H(Y|X)$. $\log_2 3 - \frac{2}{3} - \frac{2}{3} = 0.251$
- (e) $I(X;Y)$. 0.251

(f) (a)부터 (e)까지 구한 양(quantity)들을 벤 다이어그램으로 나타내시오.



4-2. KL-divergence

(a) $D(q||p) = D(p||q)$ 가 성립하지 않는 반례를 제시하시오.

ex) $p = [0.5, 0.5]$ $q = [0.1, 0.9]$
 $D(q||p) = \sum q_i \log \frac{q_i}{p_i} = 0.1 \log \frac{0.1}{0.5} + 0.9 \log \frac{0.9}{0.5} \approx 0.533$

(b) $D(p||q) \geq 0$ 임을 보이시오. (Hint : Jensen's Inequality)

$$-D(p||q) = -\sum p(x) \log \frac{q(x)}{p(x)} \leq \log \left(\sum p(x) \frac{q(x)}{p(x)} \right)$$

$$\underbrace{\qquad\qquad\qquad}_{=0}$$

$$\therefore -D(p||q) \leq 0, \\ \underline{D(p||q) \geq 0}$$

$$D(p||q) = 0.5 \log \frac{0.5}{0.1} + 0.5 \log \frac{0.5}{0.9} \approx 0.735$$

$$\therefore D(p||q) \neq D(q||p)$$

Reference

- Elements of Information Theory (2nd Ed.), T. M. Cover & J. A. Thomas
- Convex Optimization for ML, Prof. Changho Suh

Data Science Lab

담당자: 14 기 박창용, 어희정, 여준호

qkrckddyd0@yonsei.ac.kr

heejung.uh@gmail.com

asap03153@gmail.com